

Tugas Praktikum 1: Scraping & Eksplorasi Data (EDA)

Deskripsi Singkat

Pada praktikum ini, mahasiswa melakukan eksplorasi data untuk memahami karakteristik sebuah dataset: mengidentifikasi atribut, mendeteksi nilai yang hilang dan outlier, menganalisis distribusi data, serta memvisualisasikan hubungan antar atribut.

Tujuan Praktikum

1. Memahami langkah-langkah eksplorasi data (EDA).
2. Mengidentifikasi tipe atribut dalam dataset (nominal, ordinal, numerik).
3. Menganalisis nilai yang hilang dan outlier pada dataset.
4. Membuat visualisasi data untuk mendukung analisis dan interpretasi.

Ketentuan Dataset

- Dataset diperoleh melalui scraping, menggunakan tools apa pun selama gratis dan aman, misalnya:
 1. [BeautifulSoup](#)
 2. [Requests](#)
 3. Alternatif lain diperbolehkan, asal tidak berbayar.
- Jenis dataset: tabular saja, dengan ketentuan minimum 5 fitur (kolom) dan 1500 baris data.

Langkah-Langkah Praktikum

1. Scraping Dataset

- Tentukan sumber data (situs mana pun, sesuaikan ketentuan dataset di atas).
- Ambil data menggunakan library pilihan (lihat referensi di atas).
- Simpan hasil scraping mentah ke file `.csv/.json` sebelum diproses lebih lanjut, agar proses scraping tidak perlu diulang.

2. Import dan Pemahaman Dataset

- Impor dataset menggunakan `pandas`.

- Tampilkan 5 baris pertama (`.head()`) untuk memahami struktur data.
- Tampilkan info umum (`.info()`, `.shape`, `.dtypes`).
- Identifikasi tipe setiap atribut: **nominal**, **ordinal**, atau **numerik** (diskrit/kontinu).

3. Analisis Statistik dan Kualitas Data

- Hitung statistik deskriptif untuk atribut numerik: rata-rata, median, modus, standar deviasi, nilai min/maks.
- Hitung frekuensi/distribusi untuk atribut kategorikal.
- Identifikasi jumlah nilai yang hilang pada setiap atribut.
- Deteksi outlier pada atribut numerik.

4. Visualisasi Data

- Univariat: histogram/distribusi untuk atribut numerik, bar chart untuk atribut kategorikal.
- Bivariat/hubungan antar atribut: scatter plot untuk melihat hubungan dua atribut numerik, correlation heatmap, atau boxplot per kategori.
- Setiap grafik disertai interpretasi singkat (insight apa yang terlihat dari grafik tersebut).

5. Penyusunan Laporan Analisis

Tulis laporan singkat (1–2 halaman) berisi:

- Deskripsi Dataset — ringkasan atribut dan karakteristik dataset.
- Statistik Deskriptif — hasil perhitungan atribut numerik/kategorikal yang relevan.
- Penanganan Data — identifikasi nilai hilang/outlier dan langkah yang diambil.
- Visualisasi & Interpretasi — grafik dari langkah 4 beserta insight yang didapat.

Hasil yang Diharapkan

1. Statistik deskriptif untuk atribut numerik dan kategorikal.
2. Visualisasi data sesuai dataset hasil scraping (histogram, scatter plot, diagram batang, dll).
3. Identifikasi dan penanganan nilai yang hilang serta outlier.
4. Laporan analisis singkat (1–2 halaman).

Ketentuan Repository GitHub

- Setiap mahasiswa membuat **1 repository GitHub pribadi** dan memastikannya **public**.
- Repository ini dipakai untuk **seluruh tugas praktikum Data Mining selama satu semester** (bukan hanya tugas ini) — setiap tugas disimpan dalam folder terpisah di dalamnya.
- Untuk tugas ini, buat folder bernama **tugas-scrapping-eda** di dalam repository, berisi file **.ipynb** dan **.pdf** sesuai ketentuan penamaan di bawah.

Contoh struktur repo:

```
nama-repo/  
├── tugas-scrapping-eda/  
│   ├── NRP_Nama_Tugas_Scrapping_dan_EDA.ipynb  
│   └── NRP_Nama_Tugas_Scrapping_dan_EDA.pdf  
└── (folder tugas praktikum lain menyusul setiap minggunya)
```

Format Pengumpulan

- File: **.ipynb + .pdf**
- Penamaan file: **NRP_Nama_Tugas_Scrapping_dan_EDA**
- Pengumpulan: kirim **link folder tugas-scrapping-eda** pada repository GitHub melalui Google Form berikut: <https://forms.gle/Z91PQCFDfJR81uZx5>
- Deadline: **Senin, 14 September 2026**, pukul 23:59 WIB

Penilaian

Komponen	Bobot	Kriteria
Pemahaman Dataset	20%	Ketepatan identifikasi tipe atribut (nominal/ordinal/numerik)
Analisis Statistik	30%	Ketepatan perhitungan statistik deskriptif, identifikasi missing value & outlier
Visualisasi Data	30%	Kesesuaian jenis grafik dengan tipe data, kualitas interpretasi
Laporan	20%	Kerapihan, kelengkapan, dan kejelasan laporan